

Factores y Series Temporales

Clase 4, Econometría financiera: del mundo Q al mundo P

Guido Schifani

FCEN · UBA



Repaso: clases 1, 2 y 3

▶ **Acción y bono, los dos ladrillos de las finanzas**

- Acción: un pedacito de una empresa. Si la empresa vale más, tu pedacito vale más
- Bono: un préstamo. Le prestás plata a una empresa o a un país, te devuelven un interés

▶ **La tasa libre de riesgo, el 'piso' de comparación**

- Lo que paga un lugar donde CASI no hay riesgo de no cobrar (ej. una Letra del Tesoro de EE.UU. a 3 meses)
- Cualquier inversión más arriesgada tiene que ofrecer MÁS que ese piso para que valga la pena el riesgo

▶ La definición de la clase 1: retorno simple, con dividendo

$$r_t = \frac{P_t - P_{t-1} + D_t}{P_{t-1}}$$

- Ejemplo: compraste a \$100, hoy vale \$107, cobraste \$1 de dividendo $\rightarrow r = (107 - 100 + 1) / 100 = 8\%$

▶ Retorno LOGARÍTMICO

$$r_t = \ln\left(\frac{P_t}{P_{t-1}}\right)$$

- Para un movimiento diario chico da casi el mismo número: $\ln(1.08) \approx 7.7\%$, contra el 8% de arriba
- Pero el logarítmico SUMA en el tiempo sin error: $r_{\text{log}}(2 \text{ días}) = r_{\text{log}}(\text{día 1}) + r_{\text{log}}(\text{día 2})$ — la fórmula simple NO cumple eso

- ▶ **Una opción es el DERECHO (no la obligación) de comprar o vender algo, a un precio ya fijado**
 - Ejemplo: pagás \$5 hoy por el derecho a comprar una acción a \$100 dentro de 3 meses ('call')
 - Si en 3 meses vale \$120: comprás a \$100, vale \$120 → ganás \$15 (\$120-\$100-\$5 pagados)
 - Si vale \$80: no ejercés el derecho (¿para qué pagar \$100 por algo que vale \$80?), perdés solo los \$5
- ▶ **Black-Scholes (BS): la fórmula que dice cuánto DEBERÍA costar ese derecho hoy**
 - Cinco ingredientes: precio de hoy, precio pactado, tiempo hasta el vencimiento, tasa de interés, y volatilidad
 - La volatilidad (σ): qué tan agitado es el precio. Es el ÚNICO ingrediente que no se observa directo
 - Vol implícita: si conozco el precio real de la opción, despejo la fórmula al revés y encuentro qué σ la explica. La vol implícita es UN número, para UNA opción puntual. Esa limitación es la puerta de la clase 3

► El problema: la vol implícita de MUCHAS opciones no da todas iguales

- Mismo vencimiento, distinto precio pactado → las vol implícitas forman una curva con forma de sonrisa ('smile')
- Y esa sonrisa tiene otra forma distinta para cada FECHA de vencimiento: hay una componente de TIEMPO
- Black-Scholes asume una sola σ constante para todo; la sonrisa real dice que no alcanza
- BS da UN número por opción: una FOTO. Dupire (1994) da $\sigma(S,t)$: una vol que depende del precio Y del tiempo, una PELÍCULA
- Heston: proceso estocástico sobre la volatilidad
- Modelos de tasa corta
- Modelo de crédito: Default

\$1

Del mundo Q al mundo P

De valuar a estimar

▶ El seguro de tu casa

- La probabilidad REAL de que tu casa se incendie es baja: 0.1% por año, eso es P, el mundo real
- La aseguradora no te cobra como si fuera 0.1%: te cobra MÁS, como si fuera 0.3%
- ¿Por qué? Perder la casa te duele mucho más de lo que 'vale' en probabilidad pura, ese 0.3% inflado es Q

▶ En finanzas: la misma idea, con acciones y opciones

- P, el mundo real: en P el S&P sube en promedio $\mu \approx 10\%$ anual, lo que los inversores esperan ganar por arriesgar su plata
- Q es el mismo 'seguro inflado': los precios de las opciones (clase 2) ya están calculados como si los escenarios malos fueran MÁS probables de lo que realmente son

¿Por qué las clases 2-3 pudieron ignorar μ ?

- ▶ **El precio de una opción NO es una apuesta sobre dónde va el precio**
 - Es el costo de FABRICAR el payof
- ▶ **Esa receta usa σ pero no usa μ**
 - σ : qué tan agitado es el precio (lo que SÍ importa para fabricar el payoff)
 - μ : hacia dónde va el precio en promedio (lo que NO hace falta para fabricarlo)
- ▶ **El objeto de HOY**
 - P es lo que estima un histograma de retornos históricos: desde acá empezamos a necesitar μ de verdad

▶ La relación entre los dos mundos

- dQ/dP: derivada de Radon-Nikodym (teoría de la medida)

▶ dQ/dP, escenario por escenario


- Para cada escenario posible, dQ/dP responde: ¿cuánto MÁS (o menos) peso le pone el mercado, comparado con qué tan probable es en la realidad?

▶ Cómo leer el número


- $dQ/dP > 1$: escenario SOBRE-pesado, más caro de lo que 'merecería' por su probabilidad real (los crashes)
- $dQ/dP < 1$: escenario SUB-pesado, el mercado no paga de más por él (las subas grandes)

P pregunta "¿qué va a pasar?" — Q pregunta "¿cuánto debe costar?"

Mismo mundo, dos medidas — la brecha ES la prima



El cociente dQ/dP — el "pricing kernel":
densidad $\times$ aversión al riesgo



Izquierda: P (navy) es el histograma real de retornos; Q (naranja) es la misma familia de escenarios, pero con más peso puesto en las caídas (por eso su cola izquierda es más gorda) y menos peso en las subas grandes. Derecha: el cociente dQ/dP por escenario, arranca ALTO en las pérdidas grandes (el mercado las trata como mucho más probables de lo que son) y BAJA por debajo de 1 en las ganancias grandes (esos escenarios buenos están sub-pesados, nadie paga de más por la suerte). La curva baja de izquierda a derecha porque Q sistemáticamente le quita peso a lo bueno y se lo pone a lo malo, comparado con P.

- ▶ **'Cruzar a P' significa que cambia la PREGUNTA**
 - Hasta ahora: fabricar payoffs, no importa a dónde va S , el hedge lo cancela
 - Desde hoy: predecir y explicar, armar portafolios, medir el riesgo de mañana
 - En estas preguntas no hay réplica que salve: nada cancela a $\mu \rightarrow$ hay que ESTIMARLO
 - Y μ es lo más difícil de estimar de todas las finanzas

- ▶ **Hoy siempre la misma pregunta de fondo, '¿qué NO sé, y con qué herramienta lo estimo?'**
 - Primero entre ACCIONES distintas (§2-3), después en el TIEMPO de una sola serie (§4-5), con VARIAS series a la vez (§6), y con MÁS variables que datos (§7)

§2

CAPM como modelo empírico

Pregunta: ¿por qué dos acciones tienen distinto retorno promedio? · Beta · Alpha · Anomalías

▶ **El retorno LOGARÍTMICO** $r_t = \ln\left(\frac{P_t}{P_{t-1}}\right)$

- Comparamos TRES retornos distintos
- r_i : el retorno de UNA acción puntual (ej. Apple)
- r_m : el retorno del MERCADO en su conjunto (ej. el índice S&P 500, el promedio de cientos de acciones)
- r_f : la tasa libre de riesgo, el piso (ej. una Letra del Tesoro de EE.UU. a 3 meses)

▶ **El CAPM relaciona el retorno esperado de un activo con su riesgo sistemático**

$$E[r_i] = r_f + \beta_i (E[r_m] - r_f)$$

- $E[r_m] - r_f$: cuánto de más rinde el MERCADO de acciones por encima del piso seguro, la 'prima' que pide el riesgo
- Según esta fórmula, dos acciones tienen distinto retorno esperado SOLO si tienen distinto β : es la única diferencia que el CAPM reconoce entre una acción y otra

▶ En la práctica no observamos $E[r_i]$: usamos retornos REALIZADOS y corremos OLS de $(r_i - r_f)$ contra $(r_m - r_f)$ — 'en exceso' es de LOS DOS lados

β : qué mide, y un ejemplo con números

► β , qué significa

$$\beta_i = \frac{\text{Cov}(r_i, r_m)}{\text{Var}(r_m)}$$

No es arbitraria: es la SOLUCIÓN de mínimos cuadrados de ajustar $r_i \approx \alpha + \beta \cdot r_m$
— derivar e igualar a 0 devuelve exactamente Cov/Var

- β mide cuánto se mueve ESTA acción comparada con el mercado
- $\beta=1$ se mueve como el mercado · $\beta=2$: mercado +1% $\Rightarrow$ activo $\approx$ +2% · $\beta=0.5 \Rightarrow \approx$ +0.5% · $\beta \leq 0$: nulo o inverso

► Ejemplo numérico

- $r_f=5\%$, $E[r_m]=10\%$, $\beta=1.4 \Rightarrow E[r_i]=5\%+1.4 \cdot (10\%-5\%)=12\%$, lo que exigirían los inversores por ese riesgo
- Si β fuera 0.5 en vez de 1.4: $E[r_i]=5\%+0.5 \cdot (5\%)=7.5\%$, una acción más tranquila exige menos retorno

► **β tiene una consecuencia directa para el RIESGO de la acción**

- El riesgo total de una acción se separa en dos partes

$$\sigma_i^2 = \beta_i^2 \sigma_m^2 + \sigma^2(\varepsilon_i) \quad (\text{sistemático} + \text{idiosincrático})$$

- Sistemático: viene del mercado, TODAS las acciones lo comparten, no se puede diversificar armando una cartera
- Idiosincrático: propio de esa empresa (un juicio, un mal balance); armando una cartera de muchas acciones, se cancela en promedio
- Por eso el mercado solo paga por el riesgo SISTEMÁTICO (CAPM): el idiosincrático se puede eliminar diversificando

▶ **Es la MISMA fórmula del CAPM que ya vimos**

$$E[r] = r_f + \beta (E[r_m] - r_f)$$

- En un gráfico con β en el eje horizontal y retorno esperado en el vertical, esta ecuación ES una recta

▶ **Cómo se usa: ubicar acciones REALES en ese gráfico**

- Cada acción se ubica según su β y su retorno PROMEDIO observado (no el esperado teórico)
- Punto SOBRE la recta: el CAPM predijo bien, $\alpha \approx 0$
- Punto ARRIBA de la recta: rindió MÁS de lo que 'le tocaba' por su riesgo, α positivo
- Punto ABAJO de la recta: rindió MENOS de lo que 'le tocaba', α negativo

▶ La regresión estimable: $r_i - r_f = \alpha + \beta \cdot (r_m - r_f) + \varepsilon$, así se calculan $\hat{\alpha}$ y $\hat{\beta}$ de datos reales

Alpha: ¿le ganaste al mercado, o solo tomaste más riesgo?

▶ Alpha de Jensen, el intercepto de la regresión

- α = el retorno que le sobra a un activo por ENCIMA de lo que su riesgo (β) explica
- Ejemplo: un fondo rindió 15% en un año en que, según su β , 'le tocaba' 12% $\rightarrow \alpha = +3\%$, ganó de más por algo que no es solo el riesgo tomado
- $\alpha > 0$: generó valor de verdad. $\alpha = 0$: hizo lo que cualquiera hubiera hecho con ese mismo riesgo. $\alpha < 0$: perdió valor pese al riesgo tomado

▶ Sharpe, la métrica más usada de la industria


- Sharpe = $(\text{retorno} - r_f) / \sigma$: cuánto retorno EXTRA por cada unidad de riesgo TOTAL que tomaste (S&P histórico ≈ 0.45)

▶ El β no existe sin especificar cómo se lo mide, y encima se mueve


- Ventana: ¿1, 2, 5 años? Frecuencia: ¿diaria, semanal, mensual? No hay respuesta única
- El β rolling de una acción cambia con el ciclo: el β de crisis $\neq$ β de calma
- $SE(\hat{\beta})$ con 252 días típicamente ± 0.1 - 0.2 : ' $\beta = 1.3$ ' significa ' $\beta \in [1.1, 1.5]$ '

Security Market Line: CAPM empírico (acciones del S&P 500, 2020-2024)

Security Market Line — CAPM empírico (2020-2024)



Beta por acción — 2020-2024



Izq: SML teórica con betas y retornos reales, puntos sobre la línea tienen alfa positivo (verde), bajo la línea alfa negativo (rojo). Der: barras de beta por acción con alfa anual superpuesto.

§3

Fama-French y el zoológico de factores

Pregunta: si el mercado (β de §2) no alcanza, ¿qué más falta? · SMB · HML · Momentum · FF5




¿Qué es un 'factor'? Y los tres de Fama-French

- ▶ **Un factor es un patrón compartido por un GRUPO de acciones, no una acción puntual**
 - Ejemplo: 'las acciones chicas' o 'las acciones baratas' se mueven parecido entre sí, más allá del mercado general
 - Un factor se arma como una estrategia comprable: comprar un grupo, vender otro (long-short)
- ▶ **Los tres factores de Fama-French**
$$r_i - r_f = \alpha_i + \beta_i MKT + s_i SMB + h_i HML + \varepsilon_i$$
 - MKT: el mercado (el de siempre) · SMB: comprar chicas, vender grandes (premio al tamaño) · HML: comprar baratas, vender caras (premio al valor)
- ▶ Datos Ken French (Dartmouth), https://mba.tuck.dartmouth.edu/pages/faculty/ken.french/data_library.html

- ▶ **Momentum: las acciones que subieron en el último año tienden a seguir subiendo un poco más**
 - (y las que bajaron, a seguir bajando) — lo contrario de lo que uno esperaría intuitivamente
 - Carhart (1997) lo convirtió en un cuarto factor: comprar los ganadores del año, vender los perdedores
 - Premio histórico grande ($\sim 5\%$ /año), pero con crashes brutales (2009: -80% en meses)
- ▶ **Fama-French 5 factores (2015): se agregan dos más**
 - RMW (empresas rentables vs. no rentables) y CMA (invierten poco vs. mucho)
 - Con estos 5 juntos, HML deja de aportar información nueva: queda explicado por los otros

Factores Fama-French: retorno acumulado, estadísticas y correlaciones

Factores Fama-French — la evidencia empírica de las anomalías del CAPM



Izq: retornos acumulados de MKT-RF, SMB, HML y MOM, SMB y HML caen sostenidamente en esta ventana (el premio a tamaño y valor se revierte), MOM es el más estable de los cuatro. Centro: estadísticas anualizadas (MKT domina en Sharpe). Der: correlaciones entre factores, la baja correlación justifica cada adición.

- ▶ **El problema: la academia publicó CIENTOS de factores (el 'factor zoo')**
 - ¿Todos reales? Imposible: no puede haber 400 fuentes distintas de riesgo
- ▶ **Por qué pasa**
 - Si probás 400 señales al azar, ~20 van a 'funcionar' solo por casualidad (multiple testing)
 - Y solo se publican los que funcionaron: los otros 380 intentos fallidos nadie los ve (p-hacking)
 - Consecuencia: la mitad de los factores publicados se evapora al probarlos con datos nuevos (McLean-Pontiff, 2016)

\$4

Series temporales: ARIMA

Nueva pregunta, ahora en el TIEMPO: ¿el precio de mañana se predice con el de hoy? · ACF/
PACF · Box-Jenkins

▶ **AR(p): el presente depende de p valores pasados**

$$r_t = \mu + \phi_1 r_{t-1} + \dots + \phi_p r_{t-p} + \varepsilon_t$$

- Sistema con memoria, ACF decae exponencialmente, PACF se corta en p
- (el AR(1) ya lo usaron: la discretización de Vasicek de la clase 3)

▶ **MA(q): el presente depende de q shocks pasados**

$$r_t = \mu + \varepsilon_t + \theta_1 \varepsilon_{t-1} + \dots + \theta_q \varepsilon_{t-q}$$

- ACF se corta en q, PACF decae, el espejo del AR

▶ **ARIMA(p,d,q) y la receta de Box-Jenkins**

- d = cuántas veces diferenciar para llegar a estacionario (precios: d=1)
- 1. ADF para d → 2. ACF/PACF para p,q → 3. Máxima verosimilitud → 4. Residuos = ruido blanco (Ljung-Box)
- Selección de orden: AIC/BIC, el ajuste penalizado por complejidad

▶ Es EL algoritmo de la econometría clásica, funciona muy bien... donde hay señal

- ▶ **Una serie es estacionaria si su comportamiento promedio no cambia con el tiempo**
 - El promedio, qué tan dispersos son los datos, y cómo se relaciona el pasado con el presente, se mantienen ESTABLES
 - Sin eso no hay estimación posible: cada momento del tiempo sería una muestra de un solo dato

- ▶ **El diagnóstico financiero básico**
 - Los PRECIOS no son estacionarios (caminan sin límite); los RETORNOS aproximadamente sí

▶ **Si ADF y KPSS COINCIDEN: confío en el veredicto**

- ADF rechaza + KPSS no rechaza → los dos dicen 'estacionaria'
- ADF no rechaza + KPSS rechaza → los dos dicen 'no estacionaria'


▶ **Si DISCREPAN: zona gris**

- Pasa con series que están en el límite (reversión muy lenta, casi como una caminata aleatoria) — ningún test alcanza solo ahí


La zona gris de la estacionariedad: tres series, tres veredictos

ADF y KPSS tienen la nula invertida: por eso se corren juntos, nunca solos


Ruido blanco $\phi = 0$



AR(1) borderline $\phi = 0.97$



Caminata aleatoria $\phi = 1$



Ruido blanco y caminata aleatoria: ADF y KPSS acuerdan (son los casos fáciles). El AR(1) con $\phi=0.97$ es genuinamente estacionario pero CASI no lo es, y ahí los dos tests discrepan: exactamente la zona donde ningún test alcanza solo.

- ▶ **ACF: ¿qué tan parecido es el valor de HOY al de hace k días?**
 - Se calcula la correlación entre la serie y ella misma, corrida k días
- ▶ **PACF: lo mismo, pero descontando el efecto de los días INTERMEDIOS**
 - Ejemplo: si hoy se parece a hace 2 días solo PORQUE ambos se parecen a hace 1 día, la PACF en el rezago 2 lo filtra y da ~ 0
 - ACF mezcla el efecto DIRECTO de hace k días con el INDIRECTO (a través de los días del medio); PACF aísla solo el directo
- ▶ **Por qué sirven juntas: cada una delata un modelo distinto**
 - En un $AR(p)$: la ACF decae de a poco, la PACF se corta de golpe en el rezago p
 - En un $MA(q)$: es al revés, la ACF se corta en q, la PACF decae de a poco


- ▶ **El problema: más parámetros SIEMPRE ajustan el pasado igual o mejor, nunca peor**
 - Un AR(5) nunca va a explicar peor los datos YA VISTOS que un AR(1): tiene más libertad para pegarle
 - Si el criterio fuera 'mejor ajuste', siempre ganaría el modelo más complejo — el sobreajuste de siempre
- ▶ **La solución: premiar el ajuste, pero PENALIZAR la cantidad de parámetros**
$$\text{AIC} = 2k - 2\ln \hat{L} \quad \text{BIC} = k\ln n - 2\ln \hat{L}$$
 - k : cantidad de parámetros del modelo · n : cantidad de datos · $\hat{L}$: qué tan bien explica los datos (verosimilitud máxima)
 - Se elige el modelo con el AIC (o BIC) MÁS BAJO entre todos los candidatos probados
- ▶ **La diferencia entre los dos**
 - BIC penaliza MÁS fuerte cuando hay muchos datos ($\ln n$ crece; el 2 de AIC no) → BIC tiende a elegir modelos más simples que AIC
- ▶ Agregar un parámetro que casi no mejora el ajuste empeora el AIC/BIC

¿Queremos o no queremos autocorrelación? Depende de QUÉ serie


- ▶ **No hay una respuesta única: depende de qué estás mirando y para qué**
- ▶ **En los RETORNOS crudos (r_t)**
 - Si hubiera autocorrelación fuerte, sería plata gratis: predecir mañana con el dato de hoy. En acciones líquidas casi no aparece — no es que la 'querramos' o no, es lo que hay
- ▶ **En la VOLATILIDAD (r_t^2)**
 - Acá SÍ la buscamos, y aparece enorme — es la base de todo GARCH: si r_t^2 no tuviera autocorrelación, no habría nada que modelar
- ▶ **En los RESIDUOS de un modelo YA ajustado (Ljung-Box, un par de slides)**
 - Ahí NO la queremos: si queda autocorrelación en los residuos, el modelo dejó algo sin explicar y hay que agrandarlo

Análisis de autocorrelación — S&P 500 (2010-2025)


ACF — Retornos log




PACF — Retornos log



ACF — Retornos² (efecto ARCH)



Clustering de volatilidad (últimos 500 días)






ACF y PACF de retornos del SPY. La barra del rezago 0 SIEMPRE da 1 (es la serie comparada consigo misma, no cuenta como evidencia de nada) — miren desde el rezago 1: ahí las barras son CHICAS, casi todas caen DENTRO de la banda punteada, la firma de ruido blanco que acabamos de definir, la primera pista de que los retornos no tienen memoria explotable.

- ▶ **Los residuos son lo que el modelo NO explicó**
 - Residuo = dato real – lo que el modelo predijo, para cada día
 - Si el modelo es bueno, esos residuos deberían verse como RUIDO PURO, sin ningún patrón que aprovechar
- ▶ **Ljung-Box revisa eso: ¿queda algún patrón en los residuos?**
 - Mira varios rezagos a la vez (no solo el día anterior): un modelo puede parecer bien en un rezago y fallar en otro
 - Si RECHAZA: sobró estructura sin explicar, el modelo está incompleto, hay que agrandarlo
 - Si NO rechaza: los residuos son indistinguibles de ruido puro, no hay más para exprimir con un modelo lineal

Ljung-Box: la misma serie, dos modelos


Ljung-Box: H_0 = los residuos son ruido blanco (sin estructura remanente)



Un AR(2) simulado, mal especificado como AR(1) (arriba: queda estructura en el rezago 2, Ljung-Box rechaza) vs. bien especificado como AR(2) (abajo: residuos indistinguibles de ruido blanco, no rechaza en ningún rezago).

- ▶ **El resultado que van a obtener en la práctica (spoiler)**
 - ARIMA sobre retornos del SPY: pronóstico $\approx$ la media ≈ 0 , indistinguible del naive
- ▶ **Por qué: la eficiencia del mercado como teorema de punto fijo**
 - Si r_t fuera predecible con ARIMA, alguien ya lo estaría explotando, y al explotarlo, borra el patrón. La predictibilidad lineal se auto-destruye
 - Lo que queda: autocorrelaciones de ~ 0.01 , señal/ruido ínfimo, inestable
- ▶ **La lección correcta NO es 'nada se puede predecir'**
 - Los retornos (primer momento): casi imposible en horizontes cortos
 - La VOLATILIDAD (segundo momento): muy predecible, el clustering de la clase 1
 - ACF de r_t : nada. ACF de r_t^2 : enorme y persistente.
- ▶ Donde ARIMA sí sirve en finanzas: spreads (clase 7), volumen, series macro, donde hay estructura

ARIMA(1,0,0) — Predicción de retornos log del S&P 500 [datos en vivo (yfinance)]



El mejor ARIMA elegido por AIC pronostica esencialmente la media: la banda de confianza contiene todo y la predicción no aporta sobre el naive. El fracaso es el resultado, y es información. (Por qué es una RECTA: $\phi \approx -0.03$ y no significativo $\rightarrow$ el pronóstico $\hat{r}_{t+h} = \mu + \phi^h(r_t - \mu)$ converge a μ en $\sim 1-2$ días, sin memoria que estirar, no hay curva que dibujar.)


- ▶ **Otra forma de ver lo mismo: la serie de retornos es una SEÑAL con ruido, y ARMA es un FILTRO que intenta separarlos**
 - Es la misma idea que sacarle la estática a una señal de radio: separar la información real del ruido de fondo
 - Feng & Palomar (2016) mostraron que esa separación (señal vs. ruido) es matemáticamente la MISMA en electrónica y en finanzas

§5

GARCH y el VaR condicional

La MISMA pregunta de §4, pero sobre el RIESGO en vez del precio · leverage effect · EGARCH/
GJR/DCC

Volatilidad anualizada del S&P 500 — Efecto ARCH/GARCH



Volatilidad rolling (20d y 60d) como proxy del clustering que GARCH modela: los picos de 2008, 2020 y los sustos intermedios. La volatilidad 'respira', y un VaR que no respira con ella subestima el riesgo exactamente cuando más importa.

- ▶ 'Condicional' = la varianza de HOY, dado lo que ya pasó hasta ayer (no un promedio fijo de todos los años)

- ▶ La idea de Engle (Nobel 2003): la varianza de hoy depende del pasado reciente

$$r_t = \mu + \varepsilon_t, \quad \varepsilon_t = \sigma_t z_t, \quad z_t \sim N(0, 1)$$

- ▶ ARCH(1), Engle: la varianza reacciona al shock de ayer

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2$$

- ▶ GARCH(1,1), Bollerslev: + memoria de su propia varianza

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

- El hecho estilizado #1 de la clase 1 ('la calma y la tormenta se agrupan')

Símbolo	Qué es
σ_t^2	La varianza de HOY que se predice, dado todo lo que se sabe hasta ayer
ω	Constante positiva, el 'piso': garantiza que σ_t^2 nunca colapse a cero
ε_{t-1}^2	El shock de AYER al cuadrado, el tamaño de la sorpresa de retorno de ayer
α	Reactividad, cuánto pesa el shock de ayer en la varianza de hoy
σ_{t-1}^2	La varianza que el propio modelo había estimado para AYER (su predicción anterior, no el shock)
β	Persistencia, cuánto se arrastra la varianza de ayer a la de hoy

Lo que GARCH regala: se puede pronosticar la volatilidad futura, también explica las 'colas gordas'

- ▶ Hay un nivel 'normal' de largo plazo al que la volatilidad siempre vuelve

$$\bar{\sigma}^2 = \frac{\omega}{1 - \alpha - \beta}$$

- Después de un shock grande, el pronóstico de volatilidad va bajando de a poco hacia ese nivel normal, a una velocidad que depende de $\alpha + \beta$
- ▶ Esto es justo lo que ARIMA NO pudo con el retorno (§4): la varianza SÍ tiene estructura predecible

Cada día, el shock es una campana normal común y corriente

Pero la ANCHURA de esa campana (σ_t) cambia de un día a otro (el clustering)

Mezclar muchos días con anchos distintos da colas más gordas que una sola campana fija

Así aparece la curtosis ('colas gordas') sola, sin agregar ningún supuesto raro — el hecho estilizado #2 de la clase 1, ahora explicado

- ▶ **Recordemos GARCH(1,1): la varianza de hoy depende del shock de ayer, sin importar su signo**
 - Pero en la realidad, un retorno NEGATIVO dispara MÁS volatilidad futura que uno positivo del mismo tamaño
 - Ejemplo: una caída del 5% suele venir seguida de más nerviosismo que una suba del 5%
 - Nombre histórico: 'leverage effect' (Black, 1976) — una acción que cae aumenta el apalancamiento de la empresa, y eso sube su riesgo
- ▶ GARCH(1,1) simétrico NO ve esta diferencia: subestima el riesgo justo después de una caída

▶ **GARCH común: el shock de ayer pesa lo mismo, suba o baje**

- GJR-GARCH le agrega un 'interruptor': si el shock de ayer fue NEGATIVO, pesa más


$$\sigma_t^2 = \omega + (\alpha + \gamma \mathbb{1}_{\varepsilon_{t-1} < 0}) \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2$$

- Si γ es positivo: hay leverage effect, las bajadas pesan más ($\alpha + \gamma$) que las subidas (solo α)

▶ EGARCH hace lo mismo con otra receta matemática (trabaja con el logaritmo de la varianza), pero la idea de fondo es idéntica: pesar más lo negativo

$$\ln(\sigma_t^2) = \omega + \beta \ln(\sigma_{t-1}^2) + \alpha (|z_{t-1}| - \mathbb{E}[|z_{t-1}|]) + \gamma z_{t-1}$$

News Impact Curve: el mismo $|\varepsilon|$, distinta reacción según el signo



GARCH(1,1) simétrico (gris) reacciona igual a shocks + y -. GJR-GARCH (naranja) da un salto discreto en $\varepsilon < 0$. EGARCH (violeta) es asimétrico pero suave. Las tres parten de casi el mismo nivel en $\varepsilon=0$ (parámetros ilustrativos elegidos para eso), y divergen a partir de ahí según el signo del shock.

- ▶ **GARCH nos da σ_t , la volatilidad de mañana, ¿y con eso, cuánto puedo llegar a perder?**
 - Value at Risk (VaR): la pérdida máxima esperable, con una confianza dada, en un horizonte dado
 - Ejemplo: $\text{VaR}(99\%, 1 \text{ día}) = \text{USD } 1\text{M}$ significa 'hay 1% de probabilidad de perder MÁS de 1M mañana'

- ▶ **Expected Shortfall (ES): un paso más allá del VaR**
 - El VaR dice DÓNDE empieza la cola mala; el ES dice, en promedio, CUÁNTO se pierde una vez que ya se entró en esa cola
 - Por eso los reguladores (Basilea III) exigen ES, no solo VaR, para el capital de los bancos

- ▶ **El problema de usar una sola σ fija para todo el año**
 - Supone que marzo 2020 (crisis) y un agosto tranquilo tienen el mismo riesgo — obviamente no es así
- ▶ **La solución: usar la σ_t de GARCH (que cambia día a día) en vez de una σ fija**
$$\text{VaR}_t(99\%) = \mu - 2.33 \sigma_t \quad (\sigma_t \text{ del GARCH})$$
 - El límite de riesgo se agranda solo cuando la tormenta empieza: más realista, y se anticipa antes
 - En la práctica: comparamos VaR estático vs. condicional, con 2020 como prueba de fuego

	VaR ESTÁTICO	VaR CONDICIONAL (GARCH)
σ usada	Fija, una sola ventana histórica completa	σ_t de GARCH, se recalcula CADA día
Reacciona a un shock nuevo	No, tarda en "enterarse"	Sí, el límite crece apenas arranca la tormenta
Qué falla igual en los dos	La CANTIDAD total (colas más gordas que la normal)	Mismo problema — no usar GARCH

§6

PCA de la curva

Pregunta: ¿cómo estimo MUCHAS series relacionadas a la vez, en vez de una por una? · Nivel/
Pendiente/Curvatura

PCA: resumir MUCHOS números correlacionados en pocos patrones

- ▶ **El problema:** la curva de tasas tiene muchos plazos (~11), pero casi nunca se mueven de forma independiente
- ▶ **PCA (Análisis de Componentes Principales):** busca los pocos 'patrones' que explican la mayoría del movimiento conjunto de muchas variables
 - Acá el resultado es contundente: solo 3 patrones alcanzan para explicar más del 95% de cómo se mueve TODA la curva
- ▶ Mismo espíritu que Fama-French (§3): comprimir muchos números correlacionados en pocos factores

- ▶ El objeto de partida: la matriz de covarianza Σ ($N \times N$, simétrica) de los cambios diarios de los N tenores
- ▶ La pregunta que resuelve PCA: ¿qué dirección v captura la MAYOR varianza al proyectar los datos sobre ella?

$$\max_v v^\top \Sigma v \quad \text{sujeto a } \|v\| = 1$$


- Con un multiplicador de Lagrange, derivar e igualar a 0 devuelve exactamente la ecuación de autovalores:

$$\Sigma v = \lambda v$$


- Cada componente principal ES un autovector de Σ ; su autovalor λ ES la varianza que explica. % varianza de la comp. $i = \lambda_i / \sum \lambda_j$
- Las siguientes componentes maximizan lo mismo, restringidas a ser ORTOGONALES a las anteriores — por eso nivel/pendiente/curvatura no se pisan

PCA de la curva de rendimientos: 3 números resumen N tasas

Scree plot: 3 componentes explican casi todo



Las cargas de cada PC: sus FORMAS son nivel, pendiente y curvatura



Panel sintético de 10 tenores (3m a 30a). Izq: 3 componentes explican >99% de la varianza de los cambios diarios. Der: las cargas de cada componente tienen forma reconocible de nivel, pendiente y curvatura.

- ▶ **Nivel:** mueve TODA la curva para arriba o abajo por igual (el patrón más grande)
- ▶ **Pendiente:** empina o aplana la curva (corto y largo se mueven en direcciones opuestas)
- ▶ **Curvatura:** mueve la panza de la curva relativa a los extremos (el más chico de los tres)
- ▶ Nivel domina porque la política monetaria y la inflación esperada mueven TODOS los plazos a la vez

§7

Ridge y Lasso: regularizar o sobreajustar

Última pregunta del mapa: ¿qué hago con MÁS variables candidatas que datos? · L2 vs L1 · El puente al ML

▶ **Con muchos factores candidatos (§3) y pocos años de datos, OLS empieza a inventar**

- Coeficientes gigantes, signos que no tienen sentido: ajusta perfecto el pasado y falla afuera de muestra

▶ **Ridge, penalización L2: encoger todo**

$$\min_{\beta} \|r - F\beta\|^2 + \lambda \|\beta\|_2^2$$

- Encoge TODOS los coeficientes hacia cero; ninguno llega EXACTAMENTE a cero

▶ **Lasso, penalización L1: seleccionar**


$$\min_{\beta} \|r - F\beta\|^2 + \lambda \|\beta\|_1$$

- PUEDE llevar coeficientes EXACTAMENTE a cero: es una selección automática, responde la pregunta del zoológico (§3), ¿qué factores sobreviven?


Por qué Lasso anula coeficientes y Ridge no: la geometría

Mismo problema, dos formas de restricción: el rombo tiene esquinas, el círculo no

Ridge: el borde es un CÍRCULO





Lasso: el borde es un ROMBO



Las curvas de nivel (elipses) son el error de ajuste; el óptimo sin restricción está en el centro. Izquierda (Ridge, círculo): el punto donde la elipse toca la región permitida cae en un lugar CUALQUIERA del borde, con las dos coordenadas distintas de cero. Derecha (Lasso, rombo): por las puntas del rombo, ese punto de contacto suele caer justo en una ESQUINA, sobre un eje — ahí una de las dos coordenadas es EXACTAMENTE cero.

Ridge y Lasso: paths de regularización y R^2 out-of-sample

ML y modelos de factores: Ridge y LASSO para selección de factores relevantes



Superior: coeficientes (4 factores verdaderos + 6 de ruido) vs nivel de regularización, Ridge encoge todo suavemente; Lasso ANULA los factores de ruido, la geometría de la slide anterior en acción sobre un caso real. Inferior: el R^2 out-of-sample, el óptimo empata con el OLS sin perder generalización, y un λ demasiado grande sí cuesta caro.

- ▶ **Ridge y Lasso YA son machine learning**

- Función de pérdida + regularización + validación cruzada = el esqueleto de todo el ML supervisado
- Lo no lineal (árboles, redes) extiende la misma lógica

- ▶ **Pero: la validación cruzada estándar MIENTE con datos financieros**

- El método clásico (K-fold) mezcla el tiempo: puede terminar entrenando con el futuro para predecir el pasado
- Hoy plantamos el problema; la clase 6 (López de Prado) trae la caja de herramientas completa para resolverlo