

Teoría de Portafolio

Clase 5: Markowitz, Black-Litterman y Risk Parity

Guido Schifani

FCEN · UBA



Repaso clase 4

▶ CAPM empírico: una regresión

- $E[r_i] = r_f + \beta \cdot (E[r_m] - r_f)$, $\hat{\beta}$ se estima con OLS de $(r_i - r_f)$ sobre $(r_m - r_f)$
- β mide co-movimiento LINEAL con el mercado

▶ Fama-French: cuando una sola β no alcanza

- SMB, HML (y momentum) son 'anomalías' — patrones reales que el CAPM de una sola β no explica

▶ El primer momento no se predice, el segundo sí

- ARIMA empató con el naive sobre retornos (fracaso, la Hipótesis de Mercados Eficientes)
- GARCH SÍ predijo la volatilidad (clustering, persistencia $\alpha + \beta$ cercana a 1: tarda en extinguirse)

▶ Dos formas de filtrar el ruido cuando hay MUCHOS números correlacionados

- PCA: resume una matriz de covarianza Σ en pocos patrones ortogonales (autovectores, ordenados por autovalor)
- Ridge/Lasso: con más variables candidatas que datos, hay que REGULARIZAR — encoger o seleccionar, no confiar en OLS crudo

- ▶ Clase 4 usó el CAPM como herramienta **EMPÍRICA**: una regresión que se corre sobre datos
- ▶ Hoy el CAPM vuelve como **CONSECUENCIA MATEMÁTICA**: ¿qué pasa si **TODOS** los inversores hacen Markowitz?
 - Misma fórmula, origen completamente distinto — de un ajuste estadístico a un resultado de equilibrio
 - También vuelve Fama-French, con la misma pregunta: ¿SMB y HML son 'anomalías' de verdad, o riesgos que el equilibrio de hoy todavía no explica del todo?

Para Fama-French, SMB y HML son **riesgos sistémicos de equilibrio** que exigen una mayor prima por exponerse a empresas frágiles, con illiquidez o propensas a sufrir shocks económicos.

Para la visión conductual, son **anomalías por ineficiencia** causadas por sesgos cognitivos que llevan al mercado a sobrevaluar el crecimiento futuro y penalizar en exceso a las acciones castigadas o poco analizadas.


§1 Markowitz

Pregunta: ¿cómo se arma UNA cartera, a partir de MUCHOS activos? · Retorno · Riesgo · Frontera eficiente

¿Qué problema resuelve Markowitz?

- ▶ **El inversor tiene N activos disponibles y capital para repartir entre ellos**
 - La intuición ingenua: poner todo en el activo de mayor retorno esperado
 - El problema: ese retorno es **INCIERTO**
- ▶ **Markowitz (1952): el primero en formalizar la pregunta con matemática**
 - Convierte 'diversificar es prudente' en un problema de optimización preciso, resoluble
 - La industria global administra USD billones (2024) resolviendo variantes de este mismo problema
 - No se resuelve una vez y listo: con el tiempo los pesos reales se alejan de los objetivos, hay que rebalancear
 - Es el punto de partida de TODA la teoría de portafolio moderna
 - ¿por qué los inversores diversifican, si 'deberían' poner todo en el activo de mayor valor esperado?
 - Ganó el Premio Nobel de Economía en 1990 (junto a Sharpe y Miller)

Un '60/40' dejado quieto 15 años termina siendo otra cartera



'60/40' es la jerga estándar de la industria para una cartera balanceada: 60% en acciones, 40% en bonos — el benchmark clásico de 'riesgo moderado'. Simulación determinista (acciones 9%/año, bonos 3%/año, sin ruido). Sin tocar nada, el 60% inicial en acciones termina en 78% después de 15 años: la cartera se volvió MÁS arriesgada sin que nadie lo decidiera. Rebalanceando una vez por año, vuelve exacto al 60% objetivo.

El retorno esperado y el riesgo de UN activo (repaso)

- ▶ $\mu = E[r]$: el retorno que 'esperamos', en promedio
- ▶ σ : qué tan lejos de ese promedio puede desviarse el resultado — el riesgo
 - Se estiman con datos históricos, y esas estimaciones tienen error (las barras de error de β , el α que tarda décadas en confirmarse)
 - Hoy agregamos un tercer objeto: σ_{ij} , la covarianza ENTRE dos activos — cuánto se mueven juntos i y j
- ▶ La pregunta de HOY no es 'cuánto retorno espero de UN activo' — es 'cómo combino VARIOS'

El retorno de un portafolio (es un promedio ponderado)

▶ Retorno de un portafolio

$$r_p = w_1 r_1 + w_2 r_2 + \cdots + w_n r_n = w^\top r$$

- Ejemplo: 60% en acciones ($\mu=10\%$) y 40% en bonos ($\mu=4\%$)

$$\mu_p = 0.6 \times 10\% + 0.4 \times 4\% = 7.6\%$$

▶ Por qué es tan simple: linealidad de la esperanza — $E[\text{suma}] = \text{suma de } E[\cdot]$

- No importa CÓMO se correlacionen los activos entre sí: para el retorno esperado, la correlación no juega ningún rol
- Y funciona igual con posiciones cortas (algún $w_i < 0$): la fórmula no cambia

- ▶ **Uno esperaría:** σ_p también es un promedio ponderado de $\sigma_1, \sigma_2, \dots$

$$\sigma_p^2 = w^\top \Sigma w \qquad \sigma_p^2 = \sum_{i=1}^N w_i^2 \sigma_i^2 + \sum_{i=1}^N \sum_{j \neq i}^N w_i w_j \sigma_{ij}$$

- Depende de la matriz de covarianza COMPLETA, no solo de los σ individuales

- ▶ **Con 2 activos, escrita a mano, para ver de dónde sale la diferencia**

$$\sigma_p^2 = w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 + 2 w_1 w_2 \sigma_{12}$$

- Los dos primeros términos SÍ son 'lo esperado' (cada activo aporta su propio riesgo, ponderado al cuadrado)
- El tercero es un término CRUZADO que depende de cómo covarían i y j entre sí — no existe en el caso del retorno



$$\sigma_p^2 = w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 + 2 w_1 w_2 \rho_{12} \sigma_1 \sigma_2$$

Con 3 activos, el mismo patrón — pero ya con 3 términos cruzados

$$\sigma_p^2 = w_1^2 \sigma_1^2 + w_2^2 \sigma_2^2 + w_3^2 \sigma_3^2 + 2w_1 w_2 \sigma_{12} + 2w_1 w_3 \sigma_{13} + 2w_2 w_3 \sigma_{23}$$

- 3 términos 'propios' (varianzas) + 3 términos CRUZADOS (covarianzas) — uno por cada PAR de activos
- Con N activos: N términos propios + $N(N-1)/2$ términos cruzados — con solo 10 activos ya son 45 covarianzas a estimar
- ▶ Los términos cruzados crecen MUCHO más rápido que los propios a medida que agregás activos

Diversificación: por qué combinar reduce el riesgo




Izq: portafolio equi-ponderado con $\sigma_i=30\%$ y $\rho=0.30$, el riesgo converge a $\sigma \cdot \sqrt{\rho} \approx 16\%$ al agregar activos, no a cero. Der: cuanto más baja la correlación promedio, más chico ese piso — con $\rho=0$ el riesgo desaparece en el límite teórico.

Ejemplo numérico simple: 2 activos, misma volatilidad, distinta correlación

- ▶ **Dos activos, mismo $\sigma=20\%$ cada uno, mitad y mitad del capital**
 - Si $\rho=+1$ (se mueven idénticos): $\sigma_p = 20\%$, NINGUNA ganancia de diversificar
 - Si $\rho=0$ (independientes): $\sigma_p \approx 14\%$, ya bajó, gratis
 - Si $\rho=-1$ (perfectamente opuestos): $\sigma_p = 0\%$, ¡el riesgo desaparece por completo!
- ▶ Nadie encuentra $\rho=-1$ entre activos de riesgo en la vida real — pero el ejemplo muestra el mecanismo puro, sin ruido

El riesgo cae con la correlación: la curva completa

Dos activos, $\sigma=20\%$ cada uno, 50/50: el riesgo cae con la correlación





Los mismos 3 puntos del ejemplo ($\rho=+1, 0, -1$), pero mostrando TODA la curva: σ_p cae de forma continua y suave a medida que ρ baja, no es un fenómeno de todo-o-nada. La mayor parte de la ganancia de diversificar ya se consigue con ρ moderadamente bajo, no hace falta llegar a ρ negativo.

- ▶ **Con N activos, hay INFINITAS combinaciones de pesos w posibles**
 - Cada combinación da un punto (σ_p, μ_p) en un plano riesgo-retorno
- ▶ **La frontera eficiente: el borde de ARRIBA de esa nube de puntos**
 - Para cada nivel de riesgo, el MÁXIMO retorno posible con esos activos
- ▶ Cualquier portafolio que no esté en la frontera está DOMINADO por otro con más retorno para el mismo riesgo

$$\mathcal{L}(w, \lambda_1, \lambda_2) = \frac{1}{2}w^T \Sigma w - \lambda_1(w^T \mu - \mu_p) - \lambda_2(w^T \mathbf{1} - 1) \quad \sigma_p = \sqrt{\frac{C\mu_p^2 - 2A\mu_p + B}{D}}$$

Frontera eficiente: nube de portafolios, CML y portafolio tangente



Izq: miles de portafolios aleatorios coloreados por Sharpe Ratio. La curva naranja de arriba es la frontera eficiente. La línea punteada (CML) la domina cuando existe un activo libre de riesgo. Der: pesos del portafolio de mínima varianza vs. el tangente.

- ▶ El punto más a la izquierda de la frontera: el portafolio de MENOR riesgo posible, sin importar el retorno

$$w_{MVP} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^T \Sigma^{-1} \mathbf{1}}$$

- No usa NINGUNA estimación de μ — solo necesita Σ
 - Por eso muchos gestores institucionales lo usan como base 'por defecto' cuando desconfían de sus propios pronósticos de retorno
- ▶ Guardar esta idea para más adelante: 'solo necesita Σ ' va a ser importante en

$$\Sigma = \begin{pmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{pmatrix}$$

$$\Sigma^{-1} \mathbf{1} = \frac{1}{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2} \begin{pmatrix} \sigma_2^2 - \sigma_{12} \\ \sigma_1^2 - \sigma_{12} \end{pmatrix}$$

$$\mathbf{1}^T \Sigma^{-1} \mathbf{1} = \frac{\sigma_1^2 + \sigma_2^2 - 2\sigma_{12}}{\sigma_1^2 \sigma_2^2 - \sigma_{12}^2}$$

- ▶ **El problema: minimizar el riesgo, con la ÚNICA restricción de que los pesos sumen 1 (sin pedir ningún retorno objetivo)**

$$\min_w \frac{1}{2} w^\top \Sigma w \quad \text{sujeto a } w^\top 1 = 1$$

- ▶ **Lagrangiano, derivar e igualar a 0:**

$$\partial_w L = \Sigma w - \lambda 1 = 0 \Rightarrow w = \lambda \Sigma^{-1} 1$$

- Sustituyendo w en la restricción $w^\top 1 = 1$, se despeja λ , y al reemplazarlo de vuelta queda la fórmula de la diapo anterior
- ▶ Misma técnica de Lagrange que el portafolio tangente (2 diapos atrás) — acá hay UNA sola restricción (sumar 1), sin la restricción extra de 'llegar a un retorno objetivo α_0 '

- ▶ **Con un activo libre de riesgo (r_f) disponible, la mejor combinación ya no es solo un punto de la frontera**
 - Capital Market Line (CML): mezclar r_f con UN SOLO portafolio de activos riesgosos, el 'portafolio tangente'
 - Ese portafolio tangente es el que maximiza el Sharpe Ratio: $(\mu_p - r_f) / \sigma_p$
- ▶ Teorema de separación (James Tobin): TODOS los inversores, sea cual sea su tolerancia al riesgo, deberían tener la MISMA combinación de activos riesgosos — solo cambia cuánto mezclan con r_f

Qué CAMBIA matemáticamente al agregar un activo libre de riesgo

- ▶ **r_f es DETERMINÍSTICO por definición: varianza CERO, no correlaciona con NADA**

- Ahora el portafolio invierte una fracción w en activos riesgosos y $(1-w'1)$ en r_f

$$\mu_p = w^\top \mu + (1 - w^\top 1) r_f \quad \sigma_p^2 = w^\top \Sigma w$$

- El RETORNO gana un término nuevo — pero la VARIANZA es la MISMA fórmula de siempre, exactamente igual que sin r_f

- ▶ Punto sutil: parece que agregar un activo debería cambiar todo el problema, pero solo cambia la cuenta del RETORNO — el riesgo sigue viniendo 100% de los activos riesgosos, r_f no aporta ni resta nada ahí


- ▶ **$(1-w'1)$ puede ser NEGATIVO: significa pedir prestado AL activo libre de riesgo para invertir MÁS en activos riesgosos**
 - Ejemplo: $w'1=1.5$ (150% en activos riesgosos), $(1-w'1)=-0.5$ (pedís prestado el 50% extra, a tasa r_f)
 - Esto es apalancamiento (leverage): amplifica el retorno esperado Y el riesgo, en la MISMA proporción
- ▶ En la práctica hay límites (margin requirements, la tasa real para pedir prestado no es exactamente r_f) — pero la matemática del modelo lo permite sin restricción

- ▶ **Con r_f disponible, TODOS los portafolios óptimos (cualquier nivel de riesgo deseado) invierten en la MISMA combinación relativa de activos riesgosos**
 - Esa combinación fija tiene nombre: el Portafolio de Mercado M (100% en activos riesgosos, 0% en r_f)
 - Cualquier otro portafolio óptimo P es SOLO una mezcla de M y r_f — NUNCA una combinación distinta de activos riesgosos
 - Tobin: cada inversor, sin importar su aversión al riesgo, debería tener la MISMA cartera de activos riesgosos — solo cambia cuánto mezcla con r_f

La Capital Market Line: la fórmula completa


$$E(R_P) = r_f + \sigma_P \cdot \frac{E(R_M) - r_f}{\sigma_M}$$

- El retorno esperado crece LINEAL con el riesgo σ_P — ya no es la curva de la frontera sin r_f
 - La pendiente $(E(R_M) - r_f) / \sigma_M$ ES el Sharpe Ratio del portafolio de mercado
 - OJO: al apalancarte 2x, lo que se duplica es σ_P Y el EXCESO de retorno sobre r_f — NO el retorno total. r_f es la ordenada al origen, no escala con el apalancamiento
- ▶ A la izquierda de M: PRESTÁS (mezclás con r_f , menos riesgo que el mercado). A la derecha de M: PEDÍS PRESTADO (apalancado, más riesgo que el mercado)



La Capital Market Line: la MISMA recta a los dos lados de M

Capital Market Line: la MISMA recta a los dos lados de M



Ejemplo ilustrativo: $r_f = 3\%$, portafolio de mercado M con $\sigma_M = 12\%$, $\mu_M = 9\%$ (Sharpe = 0.50). A la izquierda de M, mezclar con r_f (prestar). A la derecha, apalancarse 2x (pedir prestado el equivalente al 100% del capital) duplica tanto el riesgo como el exceso de retorno, sobre la MISMA recta.

¿Maximizar Sharpe, o resolver Lagrange? Las dos dan LO MISMO

▶ Dos caminos que parecen distintos y llegan exactamente al mismo portafolio

- Camino directo: maximizar el Sharpe $(\mu_p - r_f)/\sigma_p$ — el cociente no cambia si escalás w , por eso no hace falta la restricción $w'1=1$ desde el arranque
- Camino largo: resolver Lagrange 'minimizar varianza dado un retorno objetivo α_0 ' (con r_f incluido), para CUALQUIER α_0 que elijas

$$w_0 = \lambda_1(\alpha_0) \cdot \Sigma^{-1}(\mu - r_f 1)$$

- La DIRECCIÓN $\Sigma^{-1}(\mu - r_f 1)$ es SIEMPRE la misma, sin importar qué α_0 elijas — solo cambia el escalar λ_1 adelante (el teorema de separación, otra vez)
- ▶ Como todos apuntan a la misma dirección, TODOS tienen el mismo Sharpe. El tangente es el único con $w'1=1$ (100% en activos riesgosos) — coincide exacto con maximizar Sharpe directo

Mínima varianza (MVP)

► Pregunta: ¿cuál es el portafolio de MENOR riesgo posible, sin importar el retorno?

► Solo necesita Σ — μ NO entra en la fórmula, para nada

$$w_{MVP} = \frac{\Sigma^{-1} \mathbf{1}}{\mathbf{1}^\top \Sigma^{-1} \mathbf{1}}$$

► No hace falta creer en ninguna estimación de retorno para calcularlo

Tangente (máximo Sharpe)

► Pregunta: ¿cuál es el portafolio con MEJOR retorno por unidad de riesgo?


► Necesita μ Y Σ — y también r_f

$$w^* \propto \Sigma^{-1} (\mu - r_f \mathbf{1})$$

► Tan bueno como la calidad de tu estimación de μ — el input más ruidoso de todos


- ▶ **Tres activos: SPY (acciones EE.UU.), TLT (bonos largos), GLD (oro)**
 - $\mu \approx (10\%, 3\%, 6\%), \sigma \approx (18\%, 12\%, 15\%)$ — y $\rho(\text{SPY}, \text{TLT}) \approx -0.30$ (¡negativa!)
 - Cartera de mínima varianza: $w \approx (29\%, 53\%, 18\%) \rightarrow \sigma_{\text{MVP}} \approx 8.0\%$
 - Portafolio tangente ($r_f=3\%$): $w \approx (55\%, 18\%, 26\%) \rightarrow \text{Sharpe} \approx 0.44$
- ▶ La correlación negativa SPY-TLT es la clave: TLT sube cuando SPY cae
- ▶ En 2022 esa correlación se volvió POSITIVA (suben y bajan juntos), y la frontera histórica colapsó

MVP vs. portafolio tangente: la asignación, en gráfico



Mismos datos de la diapo anterior. Menos riesgo (MVP) pide MÁS bonos (TLT, el activo más tranquilo); más Sharpe (tangente) pide MÁS acciones (SPY, el activo con mayor μ). El oro (GLD) se mantiene relativamente estable en los dos — es el diversificador de baja correlación con ambos.

La asignación óptima cambia CONTINUAMENTE, no en dos saltos



Resolviendo el problema de Markowitz para CADA retorno objetivo posible (no solo MVP y tangente): la composición óptima se desliza suavemente de 'mayoría bonos' a 'mayoría acciones' a medida que se pide más retorno. Este gráfico es la frontera eficiente, pero mostrando QUÉ HAY ADENTRO de cada punto de la curva.

- ▶ En clase 4 usamos el CAPM como una REGRESIÓN empírica: se ajusta a datos históricos
- ▶ Hoy aparece distinto: ¿qué pasa si TODOS los inversores hacen exactamente lo que acabamos de ver (Markowitz + Tobin)?
 - Si todos coinciden en cuál es la mejor receta para invertir y toda acción emitida se termina vendiendo, esa receta óptima tiene que incluir a todas las empresas en sus proporciones reales.
 - Cada acción individual queda con la misma β de siempre — pero ahora β mide su contribución al riesgo del portafolio de MERCADO, no un ajuste post-hoc
- ▶ De ahí sale la misma fórmula del CAPM — pero ahora como CONSECUENCIA del equilibrio, no como un ajuste estadístico

La misma fórmula, dos orígenes completamente distintos

Clase 4: CAPM empírico

- ▶ β se ESTIMA con una regresión OLS sobre datos históricos
- ▶ Es una herramienta: 'esto ajusta razonablemente bien'
- ▶ No necesita ningún supuesto sobre cómo se comportan los DEMÁS inversores

Clase 5: CAPM equilibrio

- ▶ β SALE de la teoría, sin necesitar datos, SI todos hacen markowitz
- ▶ Es una consecuencia: 'esto TIENE que pasar si el mercado se vacía'
- ▶ La realidad usa la versión empírica — el resultado teórico es la JUSTIFICACIÓN de por qué eso tiene sentido

§2

Por qué Markowitz falla en la práctica

Pregunta: si la matemática es tan elegante, ¿por qué casi nadie usa Markowitz puro? · Inputs ruidosos · Shrinkage

El problema no es la matemática — son los INPUTS


- ▶ **Asume que μ y Σ son CONOCIDOS, datos del problema**
 - En la realidad, se ESTIMAN con datos históricos
 - Y ya vimos en clase 4 lo ruidosas que son esas estimaciones (β con barras de error grandes, α que tarda décadas en confirmarse)
 - μ es el peor de los dos: para distinguir un retorno esperado del ruido hacen falta MUCHOS más años de los que hay disponibles; Σ se estima algo mejor, pero también con error
- ▶ El problema no es un descuido del modelo, es su limitación central en la práctica

▶ Richard Michaud bautizó el problema

- El optimizador de Markowitz no sabe distinguir SEÑAL de RUIDO
- Le da MÁS peso a los activos con la estimación de retorno MÁS optimista — que suele ser, justamente, la más ruidosa (la que menos hay que creerle)
- Resultado típico: carteras 'de esquina', concentradas en 2-3 activos con posiciones extremas (a veces cortos gigantes), nada parecido a lo que un gestor real recomendaría

Un cambio chico en μ , una cartera totalmente distinta


A y B casi gemelos ($\rho=0.98$): 0.2pp de error en μ
invierte casi toda la asignación entre ellos




Perturbar apenas un poco el retorno esperado de un activo (algo del orden del error de estimación normal) cambia drásticamente los pesos óptimos — la solución de Markowitz es extremadamente sensible a un input que, de entrada, ya es ruidoso.

Portafolios concentrados y el error que crece con N

Sensibilidad de pesos a perturbaciones en μ
($\pm 2\%$ de error en retornos esperados)



Maldición de la dimensionalidad
 N^2 covarianzas a estimar con T observaciones




Izq: ante pequeñas perturbaciones en los retornos esperados ($\pm 2\%$), los pesos del portafolio tangente fluctúan violentamente — el optimizador amplifica el ruido. Der: el error de estimación de Σ crece con la cantidad de activos N .

- ▶ **Σ tiene N varianzas + $N(N-1)/2$ covarianzas para estimar**
 - Con $N=50$ activos: 50 varianzas + 1225 covarianzas = 1275 números, todos estimados con la MISMA cantidad de datos históricos
 - Cuantos más activos metés, MÁS parámetros hay que estimar con los mismos años de historia disponibles
 - Regla práctica citada en la industria: hacen falta del orden de N^2 observaciones para estimar Σ con confianza razonable — con acciones diarias y $N=50$, son años de historia
- ▶ Cada covarianza individual queda más ruidosa cuantas más haya que estimar a la vez — no es gratis agregar activos

Crecimiento cuadrático: por qué agregar activos no es gratis


La maldición de la dimensionalidad: crecimiento cuadrático, no lineal



Las varianzas (línea discontinua) crecen LINEAL con N . Las covarianzas (línea sólida, la mayoría de los parámetros) crecen CUADRÁTICO. Con 10 activos ya hay 45 covarianzas para estimar; con 50, son 1225 — con la misma cantidad de años de historia disponibles.

- ▶ **El portafolio óptimo se ve HERMOSO con los datos que se usaron para construirlo (in-sample)**
 - Pero afuera de esa muestra (datos nuevos, el futuro real) suele rendir PEOR que un simple 1/N (equi-ponderado)
 - DeMiguel, Garlappi & Uppal (2009): probaron 14 modelos de asignación sobre datos reales — en la mayoría de los casos, NINGUNO le ganó de forma consistente al 1/N ingenuo
- ▶ Es el mismo patrón de sobreajuste que ya vieron con Ridge/Lasso en clase 4: más 'libertad' para ajustar el pasado no es gratis

El colapso out-of-sample: $N=10$ activos, Σ y μ VERDADEROS conocidos (solo hay ruido de estimación, ningún cambio de régimen)



Simulación con μ y Σ VERDADEROS conocidos (no hay cambio de régimen, solo ruido de estimación): Markowitz ajustado in-sample da Sharpe 0.61, pero evaluado con datos nuevos de la MISMA distribución cae a 0.25 — peor que el 1/N ingenuo (0.32) evaluado en las mismas condiciones.


- ▶ **Bias-variance trade-off — la misma idea que ya vieron con Ridge y Lasso en clase 4**
 - Un estimador con MENOS varianza (más estable), aunque tenga un poquito de sesgo, puede predecir MEJOR que uno 'perfecto' pero ruidoso
 - La idea acá: en vez de usar la Σ estimada directamente (muchísima varianza), MEZCLARLA con algo más simple y estable
 - Ridge encogía un VECTOR de coeficientes β hacia cero; acá se encoge una MATRIZ Σ entera hacia una estructura simple
- ▶ Exactamente la misma lógica que Ridge: encoger hacia algo simple para ganar estabilidad, a cambio de un poco de sesgo

Shrinkage de Σ : la fórmula, en una frase

$$\Sigma_{\text{shrink}} = \delta \cdot F + (1 - \delta) \cdot \hat{\Sigma}$$

- F : un objetivo simple y estable (la matriz identidad, o 'todos los activos correlacionan igual')
 - $\hat{\Sigma}$: la matriz estimada cruda, con toda su varianza y su ruido
 - $\delta \in [0,1]$: cuánto 'encogés' — $\delta=0$ es la estimación cruda, $\delta=1$ es ignorar los datos por completo
- Es un promedio ponderado entre 'confiar en los datos' y 'confiar en una estructura simple'

El trade-off, descompuesto en sus dos partes



Simulación ($N=20$ activos, $T=30$ observaciones, Σ verdadera conocida, 300 corridas) — pero ahora separando el error en sus dos ingredientes. $\delta=0$ ($\hat{\Sigma}$ cruda): sesgo ≈ 0 , pero TODA la varianza. $\delta=1$ (solo F): varianza ≈ 0 , pero TODO el sesgo. El error total (línea punteada) es la SUMA de las dos curvas, verificado exacto — y por eso tiene mínimo en un punto intermedio, nunca en los extremos.

- ▶ **Ledoit y Wolf encontraron una fórmula para el δ ÓPTIMO — el que minimiza el error esperado de estimación**
 - No hace falta elegir δ a mano ni por prueba y error: se calcula directamente de los mismos datos
 - Una línea de código: `sklearn.covariance.LedoitWolf()`
- ▶ Es EXACTAMENTE la misma familia de ideas que Ridge, aplicada a toda una matriz en vez de a un vector de coeficientes

Por qué shrinkage ayuda, pero no resuelve todo

- ▶ **Baja la varianza del estimador de Σ — los portafolios quedan menos 'erráticos' ante nuevos datos**
 - PERO: solo ataca Σ . El input MÁS ruidoso de todos, μ (el retorno esperado), sigue intacto
 - Ya vimos en clase 4: un α necesita DÉCADAS de datos para distinguirse de cero — shrinkage de Σ no arregla eso para nada
- ▶ Hace falta una idea distinta para atacar μ — ahí entra Black-Litterman

§3

Black-Litterman: la primera solución

Pregunta: ¿cómo uso mi propia opinión sin que un input ruidoso vuele toda la cartera? · Prior · Views · Bayes

- ▶ **Fischer Black (el de Black-Scholes) y Robert Litterman, trabajando en Goldman Sachs**
 - El problema que veían A DIARIO: los portafolios de Markowitz que armaban para clientes eran inestables, poco intuitivos, con posiciones cortas absurdas
 - Formalizaron el modelo en papers internos de Goldman (1990), publicado en 1992
 - Black ya era, en ese momento, uno de los nombres más influyentes de las finanzas cuantitativas — venía de fundar Black-Scholes en 1973 con Myron Scholes
- ▶ Nació de la práctica, no de la academia pura — un caso poco común en finanzas cuantitativas

La idea central: no partir de CERO, partir del EQUILIBRIO

- ▶ **En vez de estimar μ directamente de datos históricos (ruidoso), Black-Litterman arranca de un PRIOR razonable**
 - Ese prior: los retornos 'implícitos' que hacen que el portafolio de MERCADO sea el óptimo — el CAPM invertido, la idea de equilibrio de §1
 - Técnicamente: se toman los pesos de capitalización de mercado HOY y se despeja qué μ los haría óptimos — ingeniería inversa del CAPM
 - Ejemplo: si Apple pesa 7% del S&P 500 hoy, ese 7% YA contiene la opinión colectiva del mercado sobre su retorno esperado
- ▶ Es un truco elegante: en vez de estimar μ desde cero, se lo 'despeja' de los pesos que YA observamos

Después, el inversor agrega sus VIEWS propias

- ▶ **Un 'view' es una opinión concreta y cuantificada sobre el futuro**
 - Ejemplo: 'Creo que tecnología le va a ganar al mercado en 2 puntos porcentuales este año'
 - Cada view viene con un nivel de CONFIANZA: cuánto pesa esa opinión frente al prior de equilibrio
 - También se pueden meter views RELATIVOS entre dos activos: 'oro le va a ganar a los bonos en 3%', sin decir nada sobre el resto de la cartera
- ▶ No hace falta tener una opinión sobre TODOS los activos — solo sobre los que uno quiera


- ▶ **Prior (equilibrio de mercado) + Evidencia (tus views) → Posterior (μ ajustado)**
 - Cuanta más confianza le pongas a tu view, más se mueve el retorno esperado hacia lo que vos creés
 - Si tu view tiene poca confianza, el resultado queda CERCA del equilibrio — no vuela la cartera
 - Caso límite útil para entender la fórmula: confianza CERO en todas las views → Black-Litterman devuelve exactamente el equilibrio de mercado, ninguna sorpresa

$$E[R] = [(\tau\Sigma)^{-1} + P^{\top} \Omega^{-1} P]^{-1} [(\tau\Sigma)^{-1} \Pi + P^{\top} \Omega^{-1} Q]$$


- Π : el prior de equilibrio (los retornos 'implícitos' de §3, despejados de los pesos de mercado)
 - P, Q : qué activos toca cada view (P) y qué dice cada view (Q) — ej. 'oro – bonos = 3%'
 - Ω : la CONFIANZA en cada view, como una varianza — Ω chico = mucha confianza, Ω grande = casi ninguna
- Verificación del caso límite de la diapo anterior: si $\Omega \rightarrow \infty$ (confianza cero), el término de las views desaparece y $E[R] \rightarrow \Pi$ exacto, el equilibrio puro

Black-Litterman: retornos prior vs. posterior y pesos resultantes

Black-Litterman: retornos prior vs posterior
(Views: Oro+3% sobre Bonos; EM+2% sobre USA)



Pesos óptimos: portfolio de mercado vs BL



Izq: retornos de equilibrio (prior CAPM) vs. retornos Black-Litterman. Las views 'Oro supera Bonos en 3%' y 'EM supera USA en 2%' tiltan SUAVEMENTE el vector de retornos esperados, no lo reemplazan. Der: los pesos resultantes permanecen diversificados.

- ▶ **El punto de partida YA es razonable (equilibrio de mercado), no una estimación ruidosa desde cero**
 - Una view individual, aunque esté mal, solo mueve una PARTE del vector μ , no todo de una vez
 - El optimizador ya no tiene 'errores gigantes' para amplificar — el prior actúa como un ancla que impide que un solo número ruidoso vuele toda la cartera
 - El resultado: carteras mucho más estables e intuitivas que Markowitz con μ estimado a lo bruto
- ▶ Black-Litterman no 'resuelve' el problema de estimación de μ — lo ESQUIVA, empezando de un lugar mejor

- ▶ **Uno de los modelos más usados en gestión de activos institucional (fondos, family offices, algunos bancos)**
 - Popular porque combina rigor matemático con algo que un gestor humano puede EXPLICAR: 'esta cartera, porque tal view, con tal confianza'
 - También lo usan bancos centrales y fondos soberanos, donde una cartera 'rara' es políticamente costosa de justificar
 - Disponible en librerías estándar de Python (PyPortfolioOpt) — no hace falta programarlo desde cero

§4

Los límites de Black-Litterman

Pregunta: ¿ya está, arreglamos Markowitz? · Lo que Black-Litterman NO resuelve

Sigue necesitando Σ — y ahí el problema no se movió

- ▶ **Black-Litterman ataca μ (el retorno esperado) — pero Σ (la covarianza) sigue siendo la estimada de siempre**
 - Σ aparece en al menos DOS lugares de la fórmula: para despejar el prior de equilibrio, y para combinarlo con las views
 - Todo el problema de estimación de Σ de §2 sigue intacto — shrinkage ayuda, pero no es parte del modelo BL en sí mismo
- ▶ BL y shrinkage atacan problemas DISTINTOS (μ vs. Σ) — en la práctica profesional se combinan los dos juntos

- ▶ **Todo el prior de Black-Litterman asume que el mercado HOY está razonablemente bien valuado (en equilibrio)**
 - ¿Y si hay una burbuja? ¿Y si el mercado está sistemáticamente mal valuado? El prior hereda ese error, no lo corrige
 - Ejemplo histórico: en la burbuja de las 'puntocom' (1999-2000), los pesos de mercado sobrevaloraban sistemáticamente a las tecnológicas — un prior BL de esa época heredaba esa distorsión

- ▶ No es una falla técnica del modelo — es una elección filosófica: 'confiar en el mercado como punto de partida'

- ▶ **¿De dónde sale el view 'tech le gana al mercado en 2%'? De un analista, un modelo propio, una corazonada**
 - ¿Y el nivel de confianza que le ponés? También es una elección humana, no algo que 'sale de los datos' solo
 - En la industria, las views suelen salir de un COMITÉ de inversión, no de una fórmula — la subjetividad es humana, no estadística
- ▶ Black-Litterman no elimina el juicio humano de la ecuación — lo hace más CONTROLABLE, no lo hace desaparecer

¿Y si dejamos de pelear con μ directamente?

- ▶ **Markowitz necesita μ y Σ . Black-Litterman mejora μ , pero sigue siendo, en el fondo, un problema de estimación**
- ▶ **¿Y si hubiera una forma de armar una cartera razonable que NO dependa tanto de estimar retornos esperados?**
 - Es un cambio de PREGUNTA, no solo de método: en vez de '¿cuánto va a rendir cada activo?', preguntar '¿cuánto riesgo quiero tomar en cada uno?'
 - Esa segunda pregunta es mucho más fácil de responder con confianza que un pronóstico de retorno
- ▶ Ahí entra una familia de ideas completamente distinta: risk parity

\$5

Risk Parity: una filosofía completamente distinta


Pregunta: ¿y si ni siquiera necesito estimar μ ? · Igualar riesgo, no capital · HRP

La idea central: igualar la **CONTRIBUCIÓN AL RIESGO**, no el capital

- ▶ **Markowitz (y Black-Litterman) reparten CAPITAL según cuánto retorno esperado promete cada activo**
- ▶ **Risk parity reparte RIESGO: cada activo debería aportar la MISMA cantidad de riesgo total a la cartera**
 - Ejemplo rápido: acciones con el doble de volatilidad que bonos → CAPITAL desigual (33% acciones, 67% bonos) para que el RIESGO quede igual (50/50) — el capital se desbalancea A PROPÓSITO
- ▶ La palabra clave es 'contribución al riesgo', no 'cuánta plata metí' — son cosas distintas

60/40: 60% del capital, pero MUCHO más del 60% del riesgo

60/40: balanceado en plata, no en riesgo ($\sigma_{\text{acciones}}=16\%$, $\sigma_{\text{bonos}}=6\%$, $\rho=0.10$)



Cartera 60% acciones / 40% bonos ($\sigma_{\text{acciones}}=16\%$, $\sigma_{\text{bonos}}=6\%$, $\rho=0.1$). Izq: el capital SE VE balanceado. Der: la contribución de cada activo a la varianza total de la cartera — acciones aportan más de 90% del riesgo, aunque solo sean 60% de la plata.

- ▶ **Intuición simple (sin correlaciones): $w_i \propto 1/\sigma_i$ — al activo MÁS volátil, MENOS capital**
 - Ejemplo: $\sigma_{\text{acciones}}=20\%$, $\sigma_{\text{bonos}}=8\%$ → $w_{\text{acciones}} \propto 1/20$, $w_{\text{bonos}} \propto 1/8$ → los bonos reciben casi 2.5 veces más capital que las acciones
 - Con correlaciones de por medio, la cuenta exacta es más compleja (hay que igualar la contribución MARGINAL de cada uno), pero la intuición central es la misma
- ▶ No hace falta μ para NADA — solo σ y las correlaciones (Σ), otra vez un problema de covarianza, no de retornos esperados

- ▶ **Ray Dalio (Bridgewater Associates, el fondo de cobertura más grande del mundo) popularizó la idea en los años 90**
 - Empezó Bridgewater en 1975 desde su departamento en Nueva York — hoy administra más de USD 100 mil millones
 - Su fondo 'All Weather' busca rendir razonablemente bien en CUALQUIER escenario macro — inflación, deflación, crecimiento, recesión — balanceando riesgo, no capital
 - La lógica: nadie sabe con certeza qué escenario macro viene, así que en vez de apostar a uno, se balancea el riesgo entre TODOS los escenarios posibles
- ▶ Es una de las estrategias institucionales más replicadas del mundo, no solo una curiosidad académica

- ▶ **Risk parity es un caso particular: 'todos los activos aportan el MISMO riesgo'**
 - Risk budgeting generaliza: asignar deliberadamente MÁS riesgo a donde uno tiene más convicción, MENOS donde tiene menos
 - Ejemplo: un fondo que confía más en su research de crédito que en acciones puede asignarle 40% del PRESUPUESTO de riesgo a crédito, en vez de igualarlo con el resto
 - Es el puente natural entre 'no confío en μ para nada' (risk parity puro) y 'tengo algo de convicción, pero no quiero apostar todo' (Black-Litterman)
- ▶ Sigue sin necesitar μ como input directo — el 'presupuesto de riesgo' lo define el inversor, no una estimación de retorno

El problema que risk parity SÍ tiene: sigue necesitando Σ



- ▶ **Evita el problema de μ por completo**

- Pero para calcular 'contribución al riesgo' todavía hace falta Σ (varianzas Y correlaciones)
- Con MUCHOS activos, invertir/manipular Σ directamente sigue siendo numéricamente inestable (el mismo problema de §2)
- Shrinkage (§2) también se puede combinar acá — no es exclusivo de Markowitz

- ▶ Cambia de problema, no lo elimina del todo — ahí entra HRP

- ▶ **Idea: en vez de invertir Σ de una sola vez, usar CLUSTERING jerárquico — agrupar activos parecidos primero**
 - Paso 1: clustering — agrupar los activos más correlacionados entre sí (acciones con acciones, bonos con bonos)
 - Paso 2: repartir el capital de arriba hacia abajo en ese árbol de clusters, no con álgebra matricial pesada
 - Evita invertir la matriz completa → mucho más estable con MUCHOS activos

HRP: ni tan plano como EW, ni tan concentrado como Mínima Varianza



8 activos con volatilidades bien distintas (5%-22%), HRP implementado según López de Prado (2016). Izq: dendrograma — se agrupan oro/commodities, luego acciones/REITs, luego bonos/HY. Der: EW es plano ($\sigma=8.2\%$); Mínima Varianza concentra 78% en un solo activo ($\sigma=4.6\%$); HRP reparte más (máximo 46%, y le da peso real a 4-5 activos) llegando casi al mismo riesgo que MV ($\sigma=5.3\%$) sin la concentración extrema.

Comparación final: qué necesita cada familia, y qué gana

	Markowitz	Black-Litterman	Risk Parity / HRP
¿Necesita estimar μ ?	Sí, crudo	Sí, pero anclado al equilibrio	No
¿Necesita Σ completa?	Sí	Sí	Sí (HRP evita invertirla)
Estabilidad práctica	Baja	Media-alta	Alta
Filosofía	Optimizar retorno/riesgo	Bayes: prior + views	Igualar riesgo, no capital


Qué es un backtest 'walk-forward' (para leer las próximas 2 figuras)

- ▶ **La forma correcta de simular una estrategia en el tiempo, usando SOLO información que existía en cada momento**
 - En cada fecha de rebalanceo: mirar solo los últimos 252 días HACIA ATRÁS, calcular los pesos con eso, sostenerlos y medir el retorno REAL del próximo trimestre — después repetir
 - La ventana de estimación va 'caminando' junto con el calendario, de ahí el nombre
- ▶ La alternativa tramposa: usar TODA la historia (incluido el futuro) para fijar los pesos de todo el período — eso es look-ahead bias, y hace que cualquier estrategia se vea mejor de lo que en realidad hubieras logrado
- ▶ Es la versión más simple de un problema que la clase 6 retoma en serio (purged K-fold, embargo) — con datos financieros, hasta un walk-forward simple como este puede tener fugas sutiles


Performance out-of-sample: el resultado real, con datos reales

Performance out-of-sample: resultado REAL, no el que "debería" dar

Backtest walk-forward, datos reales (Yahoo Finance, 10 años, 8 ETFs)
(ventana 252d, rebalanceo trimestral)




Sharpe y Max Drawdown REALIZADOS
(no inventados)



8 ETFs reales, 10 años, backtest walk-forward genuino (ventana de 252 días, rebalanceo trimestral) — Sharpe y drawdown CALCULADOS de la curva realizada, no elegidos de antemano. Resultado honesto: en ESTA muestra (mercado alcista fuerte 2017-2026), EW ganó por Sharpe (0.66 vs. 0.46 MV y 0.52 HRP) — la menor volatilidad de MV/HRP no alcanzó a compensar su menor retorno. Max Drawdown similar entre los tres (17.5%-19.4%). Ni HRP ni MV 'ganan siempre': el resultado depende del régimen de mercado que le toque a la muestra.

¿Y si la muestra incluye una crisis? El mismo backtest, otra ventana

¿Quién gana? Depende del régimen que le toque a la muestra
(mismo backtest walk-forward, dos ventanas distintas)



Mismo backtest walk-forward, mismos 8 ETFs — extendido hasta 2007 (límite real: HYG recién tiene historia desde entonces) para poder incluir la crisis de 2008. En 2008-2020 (crisis + recuperación larga), Mínima Varianza y HRP le GANAN a Equal Weight (0.60 y 0.44 vs. 0.36) — durante la crisis de 2008 sola, el Max Drawdown de EW llegó a -36.9% contra solo -14.7% de HRP. En 2016-2026 (bull run reciente, la diapo anterior) gana EW. No hay un ganador universal: depende de si la muestra le tocó una crisis grande o no.

Lo que queda pendiente: ¿esto funciona mejor, afuera de la muestra?

- ▶ **Todo lo de hoy se puede (y se debe) comparar con un backtest honesto**
 - Pero backtestear ESTRATEGIAS DE ASIGNACIÓN tiene sus propias trampas
 - Ejemplo: rebalancear la cartera usando información que en su momento no estaba disponible (look-ahead bias) infla el resultado sin que se note
 - La clase 6 las pone sobre la mesa: purged K-fold, embargo, por qué un backtest 'lindo' puede mentir